

第十一节课 淘宝定向广告演化与天猫用户复购预测

<https://github.com/cystanford> 老师的GitHub

第十节课笔记

讲义内容概括 知识点

Question?

定向广告 VS 搜索广告

搜索广告有query，主动；定向广告为被动

$p(y=1 | ad, context, user)$

Input features:

ad 表示广告候选集

user 表示用户特征，年龄、性别

—— user profile（隐形）+user behavior（显性）

—>pooling(淘宝使用sum，youtube使用average)

context 表示上下文场景，设备，时间

粗排和精排取决于样本数量级

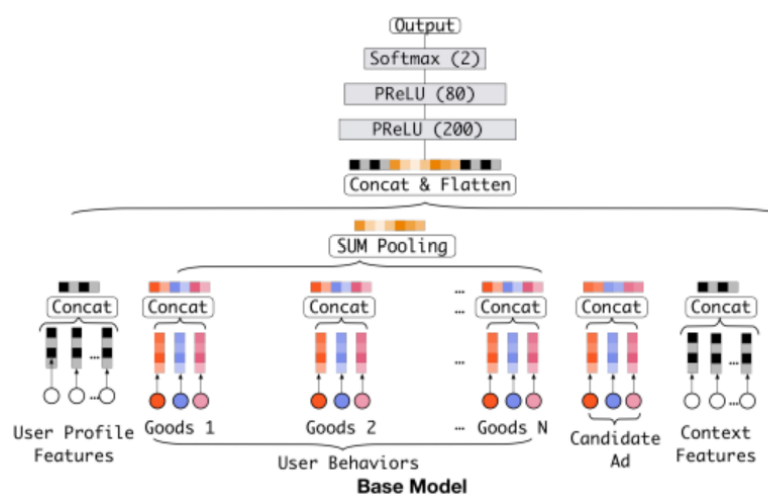
定向广告演化

LR ->

MLR(Mixed Logistic Regression,分段线性+级联，拟合高维空间线性分类面) ->

DNN (MLP 超大规模多分类问题通过softmax得到)

Base Model（传统的DNN模型）：



embedding+MLP

- Step1, Embedding Layer: 将不同的特征转换为对应的embedding表示 高维转低维
- Step2, Pooling Layer + Concat Layer: 将所有特征的embedding做拼接
- Step3, MLP Layer: 输入到多层感知机MLP（DNN），计算结果；

Loss, 损失函数采用negative log-likelihood loss

$$L = -\frac{1}{N} \sum_{(x,y) \in S} (y \log p(x) + (1-y) \log(1-p(x)))$$

不足：因为user behavior无差别的累加起来，但

- 针对电商场景中，用户的兴趣一段时间内是多样的
- 对于不同的candidate来说，浏览过的相关商品对于预测帮助更大，不相关的商品对于CTR预估并不起作用

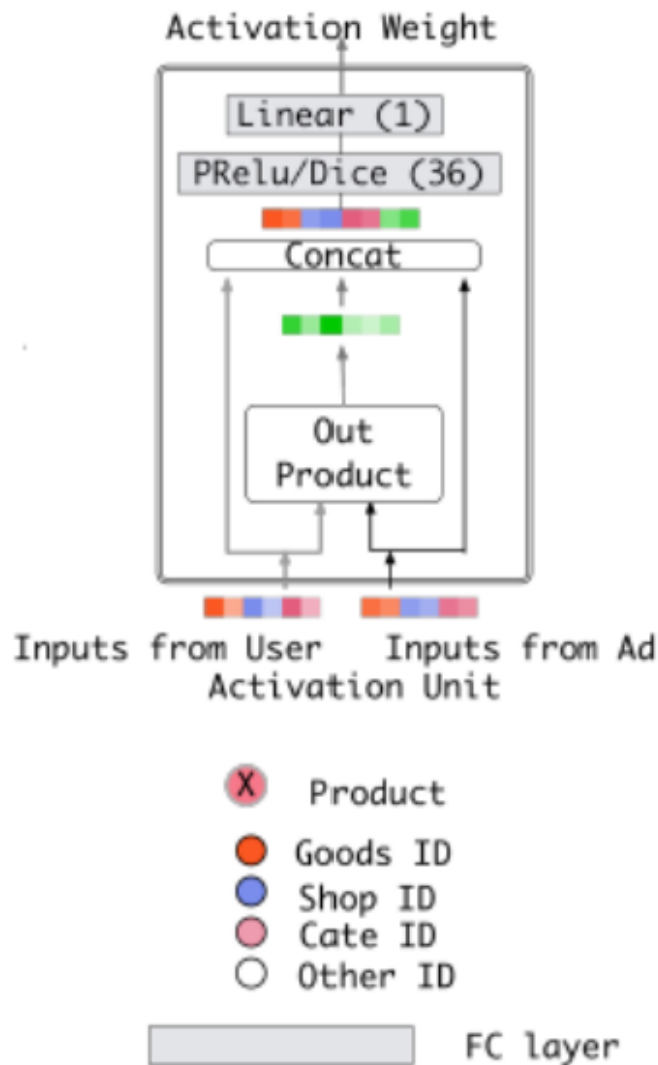
----->
DIN (Deep Interest Network: 加入了兴趣捕捉) 多尺度 (大尺度、中尺度、小尺度)

Diversity, 多样性, 一个用户可以对多种品类的东西感兴趣

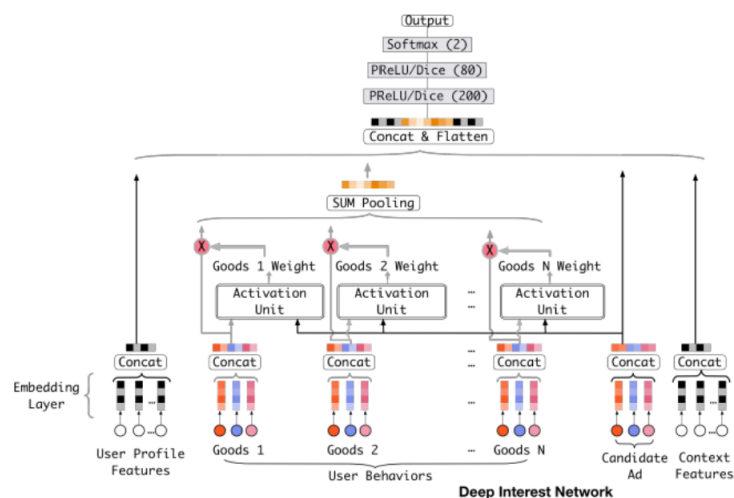
Local Activation, 局部激活, 只有部分历史行为对目前的点击预测有帮助

Attention机制: 通过Diversity和Local Activation, 给出权重法, 给embedding的特征赋权

- 在对用户行为的embedding计算上引入了attention network (也称为Activation Unit)
- 把用户历史行为特征进行embedding操作, 视为对用户兴趣的表示, 之后通过Attention Unit, 对每个兴趣表示赋予不同的权值
- Attention Weight是由用户历史行为和候选广告进行匹配计算得到的, 对应着洞察 (用户兴趣的Diversity, 以及Local Activation)



- Attention思想：在pooling的时候，与 candidate Ad 相关的商品权重大一些，与candidate Ad 不相关的商品权重小一些
- Attention分数，将candidate Ad与历史行为的每个商品发生交互来计算
- Activation Unit输出Activation Weight，输入包括用户行为embedding和候选广告embedding以外，还考虑了他们两个的外积?? —外积交叉充分计算比较简单。对于不同的candidate ad，得到的用户行为表示向量也不同
- 用SoftMax不能体现用户的行为强度



评价指标：

- 对评价指标AUC进行改进

对于每个用户单独计算自身的AUC，并根据其自身的行为数量（如点击）进行加权处理

$$AUC = \frac{\sum_{i=1}^n w_i \times AUC_i}{\sum_{i=1}^n w_i} = \frac{\sum_{i=1}^n impression_i \times AUC_i}{\sum_{i=1}^n impression_i}$$

淘宝定向广告演化

定向广告 VS

搜索广告

定向广告演化

定向广告DNN

Base Model

什么是

Attention

深度兴趣网络

DIN

Attention

Weight可视化

DIN的工程化

（评价指标，

Dice函数，

MBA-Reg正

则）

深度兴趣进化

网络DIEN

DIEN的工程化

（辅助损失函

数）

- 评价指标RelImpr RelImpr

代表相对于based model的相对改进指标，对于随机猜测的话，值AUC是0.5

$$RelImpr = \left(\frac{AUC(\text{measured model}) - 0.5}{AUC(\text{based model}) - 0.5} - 1 \right) \times 100\%$$

激活函数Dice：

Dice函数是对PReLU进行改进，引入了输入数据的统计信息；

激活函数PReLU，（Data Adaptive Activation Function，基于数据的自适应激活函数）：

$$f(s) = \begin{cases} s & \text{if } s > 0 \\ \alpha s & \text{if } s \leq 0 \end{cases} = p(s) \cdot s + (1 - p(s)) \cdot \alpha s$$

Dice：

深度会话兴趣
网络DSIN

$$f(s) = p(s) \cdot s + (1 - p(s)) \cdot \alpha s, \quad p(s) = \frac{1}{1 + e^{-\frac{s - E[s]}{\sqrt{\text{Var}[s] + \epsilon}}}}$$

天猫用户复购
预测

天猫用户商品
复购预测问题

工作流程及
Tips

熟悉Colab使
用

使用传统机器
学习

使用DNN模
型

使用Attention
机制

(DIN/DSIN)

MBA-Reg正则：???

自适应正则，mini-batch aware regularization

MBA-Reg 不是新的正则，为了工业场景专门定制 — 在mini-batch后，只关注其中是否有某特征，有则划分为一组

MBA-Reg将L2-norm 推广到样本层面，每一步迭代只计算样本相关参数



线上A/B Test效果：

CTR：点击率

CVR：展示广告购买情况，商家关注的指标

GPM：平均1000次展示，平均成交金额的比例

Online A/B Test



DIN的不足：

- 利用用户行为序列特征，直接把用户历史行为当做兴趣
- 直接用行为表示兴趣可能存在问题。因为行为是序列化产生的，行为之间存在依赖关系，比如当前时刻的兴趣往往直接导致了下一行为的发生
- 用户的兴趣是不断进化的，而DIN抽取的用户兴趣之间是独立无关联的，没有捕获到兴趣的动态进化性，比如用户对衣服的喜好，会随季节、时尚风潮以及个人品味的变化而变化，呈现一种连续的变迁趋势。

1.塔型结构的原理

2.还考虑了他们两个的外积??
Attention Weight中的dice函数是怎样应用的??

3.激活函数的作用：当输入激励达到一定强度，神经元就会被激活，产生输出信号。模拟这一细胞激活过程的函数，就叫激活函数。

4.MBA-Reg正则：???

5.辅助损失函数，是在做什么??

AUGRU?? 和 LSTM在哪里更新门为什么没有两个门好?

6.self-attention??

7.session interest



DIEN(Deep Interest Evolution Network)推算出现在的兴趣

Deep Interest Network for Click-Through Rate Prediction, 2018

<https://arxiv.org/abs/1706.06978>

解决的问题: CTR预估, 根据给定广告、用户和上下文情况等信息, 对每次广告的点击情况做出预测 对用户历史行为的洞察:

Motivation:

综合序列随机跳转多, 没有规律, 噪音大

具体到某个兴趣, 存在随时间逐渐演化的趋势

activating layer, 会话兴趣激活层-和 DIN的Local Activation Unit 作用类似??

Thinking: 心理学家是如何观察特征, 并做预测的?

(心理测试、职业发展测试)

Thinking, 你的贝尔宾团队特质是怎样的

(CO, TW,

PL分数值),

他们说明了什么

(单特征,

特征组合,

Negative

Sampling)

Thinking, 你能解释, 为什么

什么心理学测试

能帮我们做分

析预测么

Thinking, 在

工作中, 有哪些

情况, 我们

可以通过预测

来反推调整我

们的特征值

Thinking, 在

生活中, 有哪些

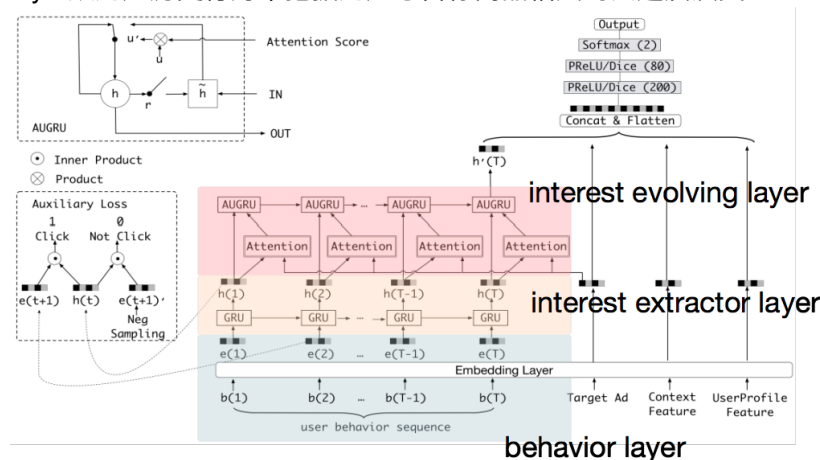
情况, 我们

可以通过预测

来反推调整我

们的特征值

使用behavior layer, interest extractor layer 以及 interest evolving layer从用户历史行为中挖掘用户与目标商品相关的兴趣及演变



引入序列模型 AUGRU (长短期记忆网络LSTM, Long Short-Term

Memory) 模拟了用户兴趣进化的过程, 将不同时间的用户兴趣串联起

来, 形成兴趣进化的链条最终把当前时刻的“兴趣向量”输入上层的多层全

连接网络, 与其他特征一起进行最终的 CTR 预估

Auxiliary loss (辅助损失函数):

增加一个负采样

$$L_{aux} = -\frac{1}{N} \left(\sum_{i=1}^N \sum_t \log \sigma(h_t^i, e_b^i[t+1]) + \log \left(1 - \sigma(h_t^i, e_b^i[t+1]) \right) \right)$$

$$L = L_{target} + \alpha \times L_{aux}$$

LSTM:

LSTM, Long Short-Term Memory, 长短记忆网络

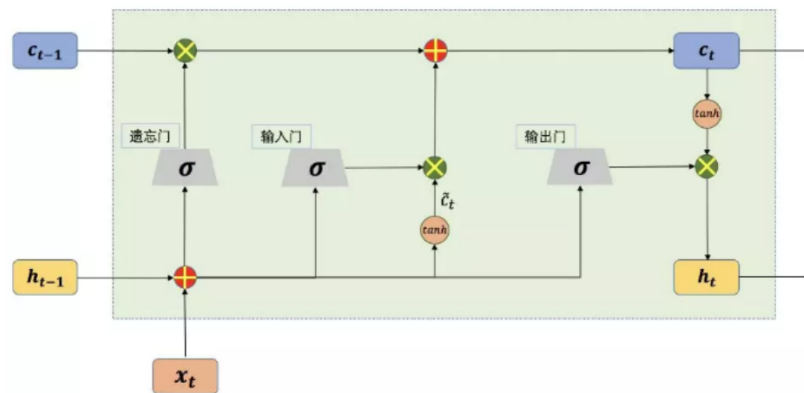
可以避免常规RNN的梯度消失, 在工业界有广泛应用

引入了三个门函数: 输入门 (Input Gate)、遗忘门 (Forget Gate)

和输出门 (Output Gate) 来控制输入值、记忆值和输出值

输入门决定了当前时刻网络的状态有多少信息需要保存到内部状态

中，遗忘门决定了过去的状态信息有多少需要丢弃 => 输入门和遗忘门是LSTM能够记忆长期依赖的关键
 输出门决定当前时刻的内部状态有多少信息需要输出给外部状态。



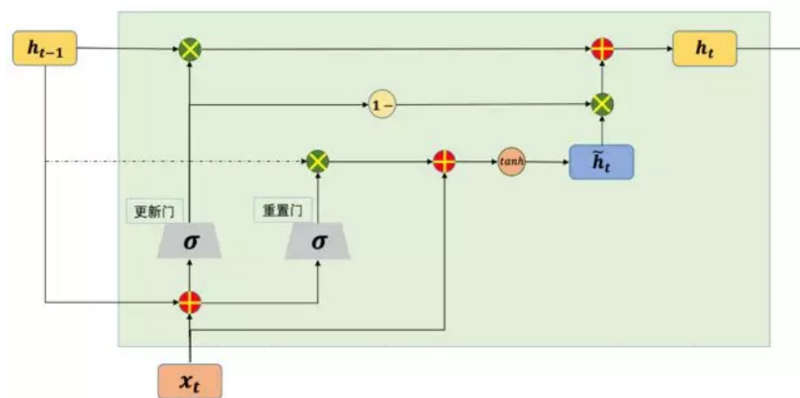
GRU:

Gated Recurrent Unit, 门控循环单元

GRU模型，只有两个门即更新门和重置门（将LSTM中的输入门和遗忘门合并成了一个门，称为更新门update gate）

没有LSTM中的内部状态和外部状态的划分，而是通过直接在当前网络的状态和上一时刻网络的状态之间添加一个线性的依赖关系，来解决梯度消失和梯度爆炸的问题

GRU是LSTM的一种变体，相比于LSTM网络结构更加简单，速度快，能避免RNN中的梯度消失，解决RNN网络中的长依赖问题



LSTM要好，但GRU效率高
 drop out—遗忘，防止过拟合

AUGRU: attention update GRU

更新门的更新由attention决定的

GRU和LSTM的作用：

使用GRU/LSTM对用户行为依赖进行建模，GRU的输入是当前时刻的顺序行为

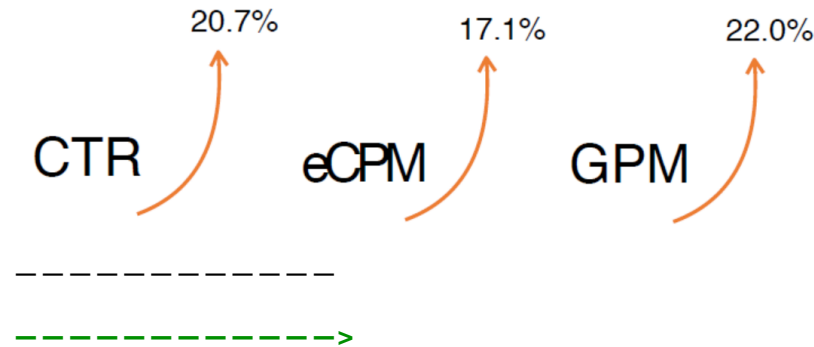
LSTM和GRU都能通过各种Gate将重要特征保留，保证其在long-term 传播时也不会被丢失

LSTM算法性能稍优于GRU算法，但是GRU模型的参数比LSTM更少，因此训练速度更快，更适合用于电子商务系统

Step1, user behavior sequence => Embedding {e1, e2, ... eT}

Step2, 对于每一个时刻e(i)通过GRU对用户行为序列进行建模，得到interest state h(i)

Step3, 将h(i)传给兴趣抽取层 (Interest Extractor Layer)



DSIN(Deep Session Interest Network)

Motivation:

将用户行为序列看成多个会话（用时间段划分）30min
会话内相近，会话与会话之间差别大

Deep Session Interest Network for Click-Through Rate Prediction, IJCAI 2019

<https://arxiv.org/abs/1905.06482>

DIEN利用用户行为序列，挖掘用户兴趣的动态演化，但忽视用户行为序列是会话

利用用户的行为序列中的多个历史会话，一个session是在给定的时间范围内发生的交互列表（用户行为列表）—聚类

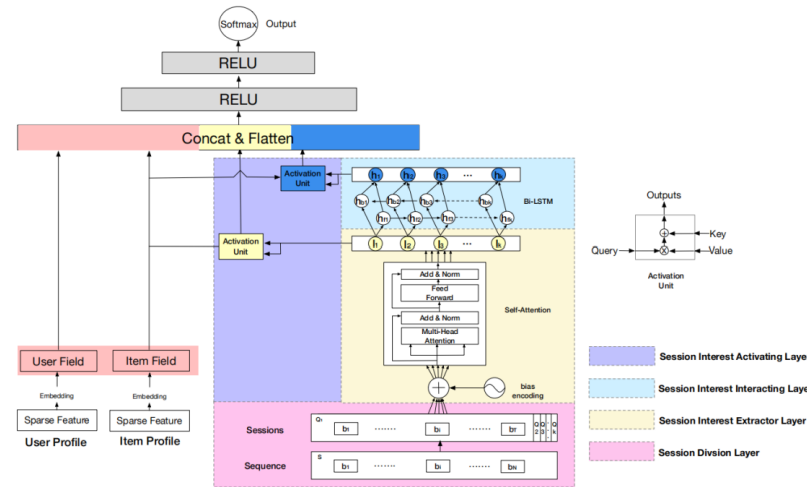
DSIN在全连接层之前，分成了两部分：

- 左边部分，将用户特征和物品特征转换对应的向量表示，主要是embedding层
- 右边部分，是对用户行为序列进行处理，从下到上分为四层：
 - session division layer, 序列切分层
 - session interest extractor layer, 会话兴趣抽取层-自注意力模块用bias encoding来捕获序列中行为的位置信息+self-attention: transformer, 通过Self-Attention将每个session兴趣转换成一个d维向量

$$BE_{(k,t,c)} = W_k^K + W_t^T + W_c^C$$

- session interest interacting layer, 会话间兴趣交互层-bi-LSTM, 特征提取更充分
- session interest activating layer, 会话兴趣激活层-和DIN的Local Activation Unit作用类似？

(蓝色feature兴趣演化是动态的，黄色feature是静态的)



1. 首先使用带有Bias Encoding（偏置编码）的Self-Attention（自我注意力）机制 => 提取用户的Session兴趣向量
2. 然后利用Bi-LSTM 对用户的Session之间的交互进行建模 => 带有上下文信息的Session兴趣向量
3. 最后利用Activation Unit（局部激活单元）自适应地学习各种会话兴趣对目标item的影响

Attention Weight可视化：？？？

- Self-Attention（自注意力机制）中的Attention权重（黄色框）=> 黄色向量 Local
- Activation Unit（局部激活单元）中的Attention权重（蓝色框）=> 蓝色向量

 -> 。。。

天猫用户商品复购预测问题

Challenge背景：

<https://tianchi.aliyun.com/competition/entrance/231576/information>

对于复购用户的预测就尤为重要，因为关注潜在的忠诚消费者，对于商家来说可以降低促销成本，增加投资回报率ROI

提供了双十一促销期间的商家和新用户数据，目标是对于给定的商家，预测新用户是否能成为忠诚用户，即未来6个月内会购买这个商家的商品

数据集：

- [data_format2.zip](#)
- 阿里数据银行后台：<https://databank.tmall.com/promotion?path=ems/databankLogin/centerAbility>

工作流程及Tips：

Step1, 采样少量样本数据更快的跑通实验 数据导入MySQL => 采样导出 使用Python 进行采样导出, 注意user_id, merchant_id对应关系

Step2, 数据加载

Step3, 特征工程 User特征, 商家特征, 用户商家交互行为特征 构造更多特征更好的进行拟合 (用户购买的商品数, 购买的品类数, 购买过的商家数, 品牌数, 时间跨度)

Step4, 使用机器学习方法进行训练

Step5, 使用测试集得出prediction.csv

总结Summary

- 记录作业内容
 - Thinking1: 电商定向广告和搜索广告有怎样的区别, 算法模型是否有差别
 - Thinking2: 定向广告都有哪些常见的使用模型, 包括Attention机制模型
 - Thinking3: DIN中的Attention机制思想和原理是怎样的
 - Thinking4: DIEN相比于DIN有哪些创新
 - Thinking5: DSIN关于Session的洞察是怎样的, 如何对Session兴趣进行表达
 - Thinking6: 如果你来设计淘宝定向广告, 会有哪些future work (即下一个阶段的idea)
 - Action1: 数据集: 天猫用户复购预测
 - <https://tianchi.aliyun.com/competition/entrance/231576/introduction>
 - 使用传统机器学习完成预测
 - 使用Attention机制的DNN模型完成预测
 - 分享交流你们的经验
 - Score > 0.66

•